

Исследовательское задание на экзамен по дисциплине Временные ряды

Анализ и прогноз валютного курса Австралийского доллара (\$AUS) к доллару США (\$USD)


ПУНКТ 1

[1] 1978 2


[1] 2021 10

Посмотрим на график целевой переменной - обменного курса AUS-USA.

Exchange rate dynamics



Обменный курс не выглядит стационарным. Проведем тест Augmented Dickey-Fuller на стационарность ряда и KPSS-тест:



Augmented Dickey-Fuller Test


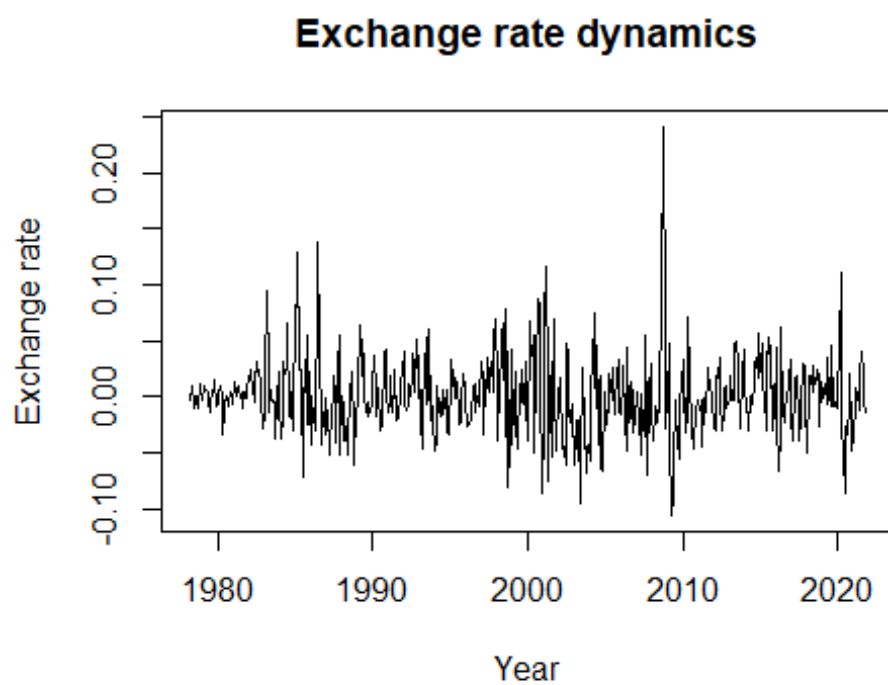
```
data: new_data  
Dickey-Fuller = -2.4001, Lag order = 8, p-value = 0.409  
alternative hypothesis: stationary
```

KPSS Test for Level Stationarity

```
data: new_data  
KPSS Level = 1.0647, Truncation lag parameter = 6, p-value = 0.01
```

Оба теста не отвергают нулевую гипотезу о нестационарности ряда.

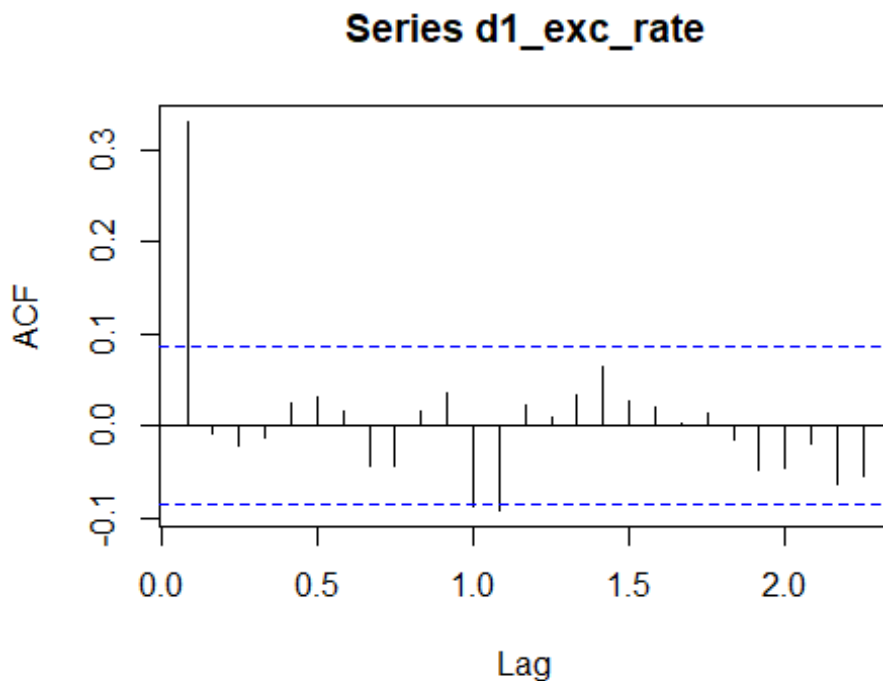
Проверим на первых разностях, является ли ряд стационарным:



Augmented Dickey-Fuller Test

data: d1_exc_rate

Dickey-Fuller = -7.5464, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary



Гипотеза о том, что ряд на первых разностях нестационарен отклоняется.

Рассмотрим AR на первом и втором лаге, согласно функции PACF:

Series: d1_exc_rate
ARIMA(1,0,0) with non-zero mean

Coefficients:


	ar1	mean
	0.3302	0.0009
s.e.	0.0412	0.0021

sigma² = 0.001075: log likelihood = 1048.37
AIC=-2090.73 AICc=-2090.68 BIC=-2077.95

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-5.616198e-06	0.03272076	0.02397271	124.3462	168.0836	0.6369355
	ACF1					
Training set	0.04387051					

Series residuals(AR1)



Box-Ljung test

```
data: residuals(AR1)
X-squared = 10.048, df = 5, p-value = 0.07388
```

Есть автокоррелляция в остатках в модели AR1.

```
Series: d1_exc_rate
ARIMA(1,0,0) with non-zero mean
```

Coefficients:

```
      ar1      mean
      0.3302  0.0009
s.e.  0.0412  0.0021
```


```
sigma^2 = 0.001075: log likelihood = 1048.37
AIC=-2090.73  AICc=-2090.68  BIC=-2077.95
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-5.616198e-06	0.03272076	0.02397271	124.3462	168.0836	0.6369355

ACF1

Training set	0.04387051
--------------	------------



```
[1] 0.03962501
```

Есть автокорелляция в остатках

```
[1] "вариант 2. через функцию Arima пакета Forecast"
```

```
[1] "AR12"
```

```
Series: d1_exc_rate
ARIMA(12,0,0) with non-zero mean
```

Coefficients:

	ar1	ar2	ar3	ar4	ar5	ar6	ar7	ar8
	0.3791	-0.1380	0.0381	-0.0363	0.0377	0.0024	0.0256	-0.0476
s.e.	0.0433	0.0463	0.0466	0.0467	0.0466	0.0466	0.0465	0.0465
	ar9	ar10	ar11	ar12	mean			
	-0.0147	0.0120	0.059	-0.1196	0.0009			
s.e.	0.0464	0.0464	0.046	0.0431	0.0018			


```
sigma^2 = 0.001056: log likelihood = 1058.45
```

```
AIC=-2088.91 AICc=-2088.08 BIC=-2029.25
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-1.415594e-06	0.03208894	0.0233153	132.6324	181.4748	0.6194686
	ACF1					
Training set	-0.001136531					

Series residuals(AR12)



Box-Ljung test


data: residuals(AR12)

X-squared = 0.059539, df = -6, p-value = NA

В AR2 Нет автокорреляции в остатках.

Среди AR моделей самой подходящей оказалась модель AR(12)

Теперь рассмотрим модели типа МА.



Модель MA1

```
Series: data[, 2]  
ARIMA(0,1,1) with drift
```

Coefficients:


	ma1	drift
	0.3782	9e-04
s.e.	0.0405	2e-03

```
sigma^2 = 0.001055: log likelihood = 1053.15
```

```
AIC=-2100.3 AICc=-2100.25 BIC=-2087.51
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-1.148988e-06	0.0323914	0.02356179	-0.01012133	1.75703	0.2008557
	ACF1					
Training set	0.0009212042					



```
[1] 0.9803216
```

При проверки модели MA1: Автокорреляции в остатках нет

Теперь рассмотрим MA2:

```
Series: data[, 2]
ARIMA(0,1,2) with drift
```

Coefficients:


	ma1	ma2	drift
	0.3784	0.0006	9e-04
s.e.	0.0438	0.0450	2e-03

```
sigma^2 = 0.001057: log likelihood = 1053.15
```

```
AIC=-2098.3 AICc=-2098.22 BIC=-2081.25
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-6.397493e-07	0.0323914	0.02356308	-0.0100618	1.757117	0.2008667
	ACF1					
Training set	0.0007101787					



Автокорреляции в остатках нет.

Проверим теперь модели ARMA

```
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 x o o o o o o o o o o o x o
1 x x o o o o o o o o o x x o
2 x x x o o o o o o o o o o o
3 x o x o o o o o o o o o o o
4 x x x x o o o o o o o o o o
5 x o x x o o o o o o o o o o
6 x o x x o o o o o o o o o o
7 o x x x x o o o o o o o o o
```

Проверим модели ARMA(1,2)


```
Series: data[, 2]
ARIMA(1,1,2) with drift
```

```
Coefficients:
      ar1      ma1      ma2      drift
      0.1750  0.2021 -0.0675  0.0009
s.e.    7.5342  7.5748  2.9473  0.0019
```

```
sigma^2 = 0.001059: log likelihood = 1053.15
AIC=-2096.3   AICc=-2096.18   BIC=-2074.99
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-7.41285e-07	0.0323914	0.02355814	-0.01016071	1.756793	0.2008246
ACF1						
Training set	0.002087015					



[1] 0.8622184

Автокорреляции в остатках нет

Рассмотрим ARMA(3,1):

Series: data[, 2]
ARIMA(3,1,1) with drift


Coefficients:

	ar1	ar2	ar3	ma1	drift
	-0.6141	0.2360	-0.1198	1.0000	0.0009
s.e.	0.0434	0.0499	0.0433	0.0057	0.0019

sigma^2 = 0.001051: log likelihood = 1054.75
AIC=-2097.49 AICc=-2097.33 BIC=-2071.92

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-2.205081e-05	0.03223615	0.02349743	-0.01275315	1.753283	0.2003071
ACF1						
Training set	0.002494735					



[1] 0.7034313

Автокорреляции в остатках почти нет (на графике ACF выпирает 13 период).


Посмотрим на параметры моделей, чтобы выбрать лучшую

	loglike	AIC	BIC
AR12	1058.455	-2088.910	-2029.249
MA1	1053.148	-2100.295	-2087.511
MA2	1053.148	-2098.296	-2081.250
ARMA12	1053.148	-2096.296	-2074.989
ARMA31	1054.747	-2097.493	-2071.924


MA1 по всем параметрам лучше MA2, так же хорошие показатели у модели ARMA(1,2). Мы выбираем эти модели.

Сделаем прогноз по этим моделям:

Forecasts from ARIMA(0,1,1) with drift



Forecasts from ARIMA(1,1,2) with drift



ARCH-эффект

Проверим модели на нормальность распределения и на наличие автокорреляции в квадратах остатков (arch-эффект)

Box-Ljung test

data: residuals(MA1)^2


X-squared = 32.364, df = 5, p-value = 5.032e-06

Shapiro-Wilk normality test

data: d1_exc_rate

W = 0.95097, p-value = 3.597e-12

Series residuals(MA1)^2



В квадратах остатков модели MA1 нет нормального распределения. В них так же наблюдается автокорреляция.

Box-Ljung test


data: residuals(ARMA12)^2

X-squared = 32.23, df = 3, p-value = 4.681e-07

Shapiro-Wilk normality test

data: d1_exc_rate

W = 0.95097, p-value = 3.597e-12




В квадратах остатков модели ARMA1 нет нормального распределения. В них так же наблюдается автокорреляция.


Для модели ARMA(1,2) попробуем модели GARCH

AR/MA															
	0	1	2	3	4	5	6	7	8	9	10	11	12	13	
0	o	x	o	o	o	x	o	o	o	o	o	x	o	o	
1	x	x	o	o	o	o	o	o	o	o	o	x	o	o	
2	x	o	o	o	o	o	o	o	o	o	o	o	o	o	
3	x	o	x	o	o	o	o	o	o	o	o	o	o	o	
4	o	x	o	x	o	o	o	o	o	o	o	o	o	o	
5	x	x	x	x	x	o	o	o	o	o	o	o	o	o	
6	x	o	o	x	x	o	o	o	o	o	o	o	o	o	
7	x	x	o	x	o	x	o	o	o	o	o	o	o	o	

Series residuals(garch.fit1)^2



Series residuals(garch.fit1)^2



Box-Ljung test

```
data: residuals(garch.fit1)^2  
X-squared = 28.107, df = 3, p-value = 3.448e-06
```


ARMA(1,2)+sGARCH

```
#ARCH-GARCH
d1_exc_rate<-diff(data[,2], differences=1) #на всякий случай еще раз
# garch_ord = c(c(1, 1),c(1, 2),c(2, 1),c(2, 2),c(6, 1),c(6, 2))

stat_garch=c()
for (i in 1:2){
  for (j in 0:2){
    spec = ugarchspec(variance.model = list(model = 'sGARCH',garchOrder = c(i,j)
), mean.model = list(armaOrder = c(1, 2), include.mean = TRUE), distribution.mod
el = "std")
    garch.fit1 = ugarchfit(spec, d1_exc_rate)
    box = Box.test(residuals(garch.fit1)^2, lag = 6, type = c("Ljung-Box"), fitd
f = i+j)
    stat_garch = append(stat_garch, box$p.value)}}
stat_garch

[1] 1.936718e-04 1.132642e-05 1.141332e-06 3.762532e-06 3.381291e-06
[6] 7.880291e-07
```

Нигде не удастся убрать автокорреляцию.

Рассмотрим ARMA(1,2) + apARCH, eGARCH, iGARCH, csGARCH

```
[1] 0.0001637726
[1] 2.030128e-05
[1] 3.314874e-05
[1] 2.803265e-05
```

MA(1)+sGARCH + apARCH



```
[1] 7.335625e-06 1.614072e-06 4.400461e-07 2.835058e-06 4.362559e-07
[6] 9.354022e-08
[1] 7.758745e-06
```

Проверим наличие автокорреляции в квадратах остатков (arch-эффект) модели ARMA12

Полностью убрать автокорреляцию квадратов остатков не получается, поэтому мы выбрали модель, которая снизила её лучше всего, это ARMA1_2 + ARCH(1.0). P_VALUE = 0.0001936718

Составим прогноз, учитывая arch-эффект


Прогноз ARMA(1,2)+ARCH[1]



Модель с GARCH не применяется далее, что как не устраняет автокорреляцию остатков.

Структурные разрывы

За долгосрочный прогноз отвечает коэффициент α_0 . Важно наличие структурного разрыва в интерсепте (коэффициенте α_0). У нас достаточно большая выборка, поэтому мы для поиска структурных разрывов проверяем Sup-F тест.





[1] 288

supF test

data: stat

sup.F = 4.2454, p-value = 0.7568




[1] 87

supF test

```
data: stat  
sup.F = 5.756, p-value = 0.7273
```

Sup-F тест показывает, что структурных разрывов нет.


Попробуем найти разрывы методом CUSUM



OLS-based CUSUM test

```
data: stat  
S0 = 0.82084, p-value = 0.5106
```

OLS-based CUSUM test



OLS-based CUSUM test

data: stat


$S_0 = 1.0834$, p-value = 0.1911

Структурных разрывов нет


VAR-модель

Посмотрим на графики прочих (объясняющих) переменных:

Other variables




Other variables




Займемся нормализацией переменных. Переменные 5,6,7,8,19,20,21,22 - нужно логарифмировать. Явно прослеживается экспоненциальный тренд. После логарифмирования:

Other variables



Other variables



Проверим, какие из рядов являются стационарными. Значения p-value ADF-теста для каждой из переменных:

```
[1] 0.40896718 0.51575053 0.06760807 0.99000000 0.69891684 0.51718757
[7] 0.99000000 0.29595425 0.16426778 0.48478288 0.08120415 0.76805548
```



```
[13] 0.63310878 0.06005052 0.05432413 0.01000000 0.01000000 0.01146369  
[19] 0.37396909 0.50648295 0.53869804
```

```
[1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE  
[13] FALSE FALSE FALSE TRUE TRUE TRUE FALSE FALSE FALSE
```

Только ряды 17-19-е являются стационарными. Перейдем лучше к первым разностям:

```
[1] 0.0100000 0.0100000 0.0100000 0.0100000 0.0100000 0.0100000 0.0100000  
[8] 0.0100000 0.0100000 0.0100000 0.0100000 0.0100000 0.9333169 0.0100000  
[15] 0.0100000 0.0100000 0.0100000 0.0100000 0.0100000 0.0100000 0.0100000
```

```
[1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE  
[13] FALSE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
```

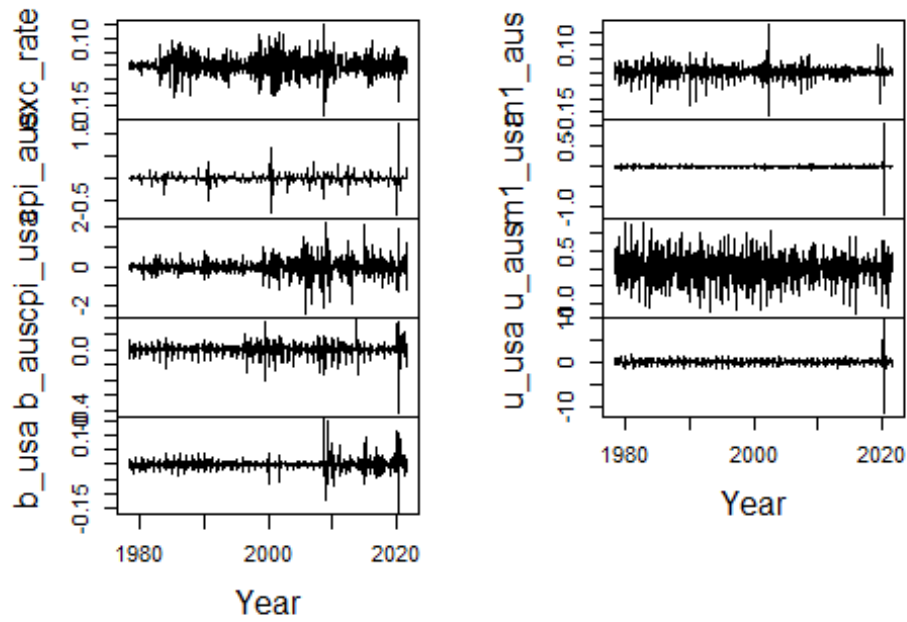
Одна переменная все равно не стационарна, поэтому перейдем ко 2-м разностям:

Приведенные ко 2-м разностям ряды:


```
[1] 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01 0.01  
[16] 0.01 0.01 0.01 0.01 0.01 0.01
```

```
[1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE  
[16] TRUE TRUE TRUE TRUE TRUE TRUE
```


Other variables



Other variables



Other variables



Теперь все временные ряды стационарны, можно с ними работать дальше.

Чтобы найти переменные, влияющие на обменный курс, проведем тест Грэнджера на причинность.

Ниже представлены p-value в тесте:

номер_переменной	переменная	p_value	значимость
1	3 cpi_aus	0.030804495	FALSE
2	4 cpi_usa	0.076917405	FALSE
3	5 b_aus	0.255800907	FALSE
4	6 b_usa	0.130137487	FALSE
5	7 m1_aus	0.115028002	FALSE
6	8 m1_usa	0.203471917	FALSE
7	9 u_aus	0.296420185	FALSE
8	10 u_usa	0.955999390	FALSE
9	11 gdp_aus	0.933601468	FALSE
10	12 gdp_usa	0.598878400	FALSE
11	13 def_aus	0.001729875	FALSE
12	14 def_usa	0.029298135	FALSE
13	15 int_aus	0.561641476	FALSE
14	16 int_usa	0.999896698	FALSE
15	17 mark_aus	0.832791446	FALSE
16	18 mark_usa	0.817819156	FALSE
17	19 exp_aus	0.861757281	FALSE
18	20 exp_usa	0.072738507	FALSE
19	21 imp_aus	0.825311070	FALSE
20	22 imp_usa	0.904603453	FALSE

При включении в модель по отдельности некоторые переменные, а именно:


- дефлятор ВВП Австралии, (<0.01)
- дефлятор ВВП США, (<0.05)
- уровень цен в Австралии, (<0.05)
- уровень цен в США, (<0.1)
- объем экспорта США (<0.1)

уменьшают ошибку прогноза и следовательно улучшают предсказание обменного курса \$AU-\$US.

Прочие переменные, а именно: уровень цен в США, денежные агрегаты, безработица, ВВП, %-ная ставка, индекс рынка, импорт и экспорт в обеих странах - не оказывают статистически значимого влияния на обменный курс на 5%-ном уровне значимости.

Так, например, выглядят кросс-корреляционная функция для обменного курса и самой значимой переменной - дефлятора ВВП Австралии:

Обменный курс \$AU-\$US - дефлятор ВВП Австралии



Оцениваем параметры VAR модели двух переменных:

AIC(n)	HQ(n)	SC(n)	FPE(n)
15	12	4	15

Рекомендуется брать 15 лагов

	exc_rate	def_au
exc_rate	1.00000000	-0.09638211
def_au	-0.09638211	1.00000000

Hosking, LiMcLeod: модель с 2-мя переменными без ограничений

```
lags statistic df p-value
56 112.9419 112 0.4572786

lags statistic df p-value
56 116.6319 112 0.3632713
```

Модель получилась с теоретически плохой частотой

Сравниваем нашу модель без ограничений с ARMA(1,1,2)

```
[1] "F-sttistics"
```

```
[1] 0.968914
```

```
[1] "p-value"
```

```
[1] 0.5394171
```

Качество модели VAR(15), судя по F-критерию, превосходит качество нашей модели ARIMA(1,1,2)

Попробуем улучшить нашу модель

Hosking, LiMcLeod-test: модель с двумя переменными с ограничениями

```
lags statistic df p-value
42 60.81035 56 0.3068688

lags statistic df p-value
42 64.1651 56 0.2120736
```

Улучшить не получилось, у неё все ещё плохая частота

```
[1] "F-stat"
```

```
[1] 1.371728
```

```
[1] "qf"
```

```
[1] 1.647172
```

```
[1] "p-value"
```

```
[1] 0.07110325
```

2. Построим теперь трёхпеременную VAR-модель.

```
AIC(n) HQ(n) SC(n) FPE(n)
27 4 3 27
```

Рекомендуется брать 27 лагов

Hosking, LiMcLeod: модель с 2-мя переменными без ограничений

```
lags statistic df p-value
40.5 125.0688 121.5 0.3938055

lags statistic df p-value
40.5 133.2713 121.5 0.2193224
```

Эта модель получилась с теоретически хорошей частотой

Сравниваем нашу модель без ограничений с ARMA(1,1,2)

```
[1] "f-критическое"
```

```
[1] 1.475101
```

```
[1] "f-статистика"
```

```
[1] 0.9925665
```

Качество трёхпеременной модели VAR(27), судя по F-критерию, превосходит качество нашей модели ARIMA(1,1,2)

Попробуем улучшить нашу модель

Hosking, LiMcLeod: модель с 2-мя переменными без ограничений

```
lags statistic    df    p-value
40.5  132.7933 121.5 0.2279463
```

```
lags statistic    df    p-value
40.5   140.644 121.5 0.1129123
```

Мы смогли сократить нашу модель, при этом сохранив отсутствие авто и кросскорреляции в остатках на 10% уровне

Сравним нашу модель с ограничениями по F-stat с моделью ARMA.

```
[1] "F-статистика"
```

```
[1] 1.693994
```

```
[1] "F-Критическое"
```

```
[1] 1.565994
```

Модель с ограничениями всё ещё лучше модели ARMA

Сравним нашу трёхпеременную модель с двухпеременной моделью

```
[1] "Hosking, LiMcLeod: модель с 2-мя переменными с ограничениями"
```

```
lags statistic    df    p-value
56  116.2818 112 0.3718553
```

```
lags statistic    df    p-value
56  119.8275 112 0.2892442
```

```
[1] "модель с 3-мя переменными"
```

```
lags statistic    df    p-value
54   296.418 243 0.01086519
```

```
lags statistic    df    p-value
54  300.0004 243 0.007405917
```

```
[1] 7.199473
```

```
[1] "F крит 1%"
```

```
[1] 2.227861
```

```
[1] "p-val"
```

```
[1] 5.382428e-12
```

Наша модель с тремя переменными лучше модели с двумя переменными

3. Попробуем теперь модель с четырьмя переменными

AIC(n)	HQ(n)	SC(n)	FPE(n)
12	6	3	12

Рекомендуется брать 12 лагов

Hosking, LiMcLeod: модель с 3-мя переменными без ограничений

lags	statistic	df	p-value
18	145.3947	96	0.0008569292

lags	statistic	df	p-value
18	146.9415	96	0.0006398172

У нашей модели присутствует кросс и автокорреляция в остатках

Сравниваем нашу модель без ограничений с ARMA(1,1,2)

```
[1] "F-stat"
```

```
[1] 0.8338694
```

```
[1] "pf"
```

```
[1] 0.769866
```

Качество трёхпеременной модели VAR(27), судя по F-критерию, немного превосходит качество нашей модели ARIMA(1,1,2)

Попробуем улучшить нашу модель

Hosking, LiMcLeod: модель с 4-мя переменными и с ограничениями

lags	statistic	df	p-value
24	261.6113	192	0.0006212704

lags	statistic	df	p-value
24	262.128	192	0.0005761648

Сравним нашу модель четырех переменных с ограничениями по F-stat с моделью ARMA.

```
[1] "F крит 1%"
```

```
[1] 1.167573
```

```
[1] "qf"
```

```
[1] 1.703783
```

```
[1] "pf"
```

```
[1] 0.2433874
```

Наша модель с ограничениями получилась хуже модели ARMA

Сравним нашу четырёхпеременную модель с трёхпеременной моделью

```
[1] "Hosking, LiMcLeod: модель с 3-мя переменными"
```

```
lags statistic df      p-value
54  296.418 243 0.01086519
```

```
lags statistic df      p-value
54  300.0004 243 0.007405917
```

```
[1] "Hosking6 LiMcLeod: модель с 4-мя переменными"
```

```
lags statistic df      p-value
24  260.2397 192 0.0007576149
```

```
lags statistic df      p-value
24  260.7322 192 0.0007057123
```

```
[1] "F-статистика"
```

```
[1] -6.254021
```

```
[1] "F крит 1%"
```

```
[1] 2.119861
```

```
[1] "p-val"
```

```
[1] 1
```

Наша модель с четырьмя переменными хуже модели с тремя переменными

4. Попробуем теперь модель с пятью переменными

AIC(n)	HQ(n)	SC(n)	FPE(n)
27	12	6	27

Рекомендуется брать 27 лагов

Hosking, LiMcLeod тест: модель с 5 переменными:

```
lags statistic df      p-value
54  924.2103 675 5.006485e-10
```

```
lags statistic df      p-value
54  931.4683 675 1.811963e-10
```

Есть авто- кросс- корреляция.

Сравниваем нашу модель без ограничений с ARMA(1,1,2)


```
[1] "F-stat"
```

```
[1] 0.7589273
```

```
[1] "p-val"
```

```
[1] 0.9615533
```

Качество трёхпеременной модели VAR(27), судя по F-критерию, хуже нашей модели ARIMA(1,1,2)

Попробуем улучшить нашу модель

Hosking, LiMcLeod test: модель с 5 переменными:

lags	statistic	df	p-value
54	1184.781	675	0

lags	statistic	df	p-value
54	1186.613	675	0

Есть авто-кросс-корреляция.

Сравним нашу модель с ограничениями по F-stat с моделью ARMA.

```
[1] "F-stat"
```

```
[1] 1.167573
```

```
[1] "qf"
```

```
[1] 1.703783
```

```
[1] "pf"
```

```
[1] 0.2433874
```

Наша модель с ограничениями получилась хуже модели ARMA

5. Попробуем теперь модель с шестью переменными

AIC(n)	HQ(n)	SC(n)	FPE(n)
27	11	3	16

Рекомендуется брать 27 лагов

Hosking, LiMcLeod: модель с 6 переменными:

lags	statistic	df	p-value
54	1404.099	972	0

lags	statistic	df	p-value
54	1412.323	972	0

Присутствует авто-кросс-корреляция.

Сравниваем нашу модель без ограничений с ARMA(1,1,2)

```
[1] "F-statistics"
```

```
[1] 0.6271618
```

```
[1] "p-value"
```

```
[1] 0.9988514
```

Качество модели VAR, судя по F-критерию, хуже нашей модели ARIMA(1,1,2)
Попробуем улучшить нашу модель

Hosking, LiMcLeod: модель Restricted VAR5:

```
lags statistic df p-value
54 1445.561 972 0
```

```
lags statistic df p-value
54 1454.171 972 0
```

Присутствует авто- кросс- корреляция

Сравним нашу модель с ограничениями по F-stat с моделью ARMA.

```
[1] "F-statistics"
```

```
[1] 1.511772
```

```
[1] "qf"
```

```
[1] 1.442267
```

```
[1] "p-value"
```

```
[1] 0.003229083
```

Наша модель с ограничениями получилась чуть лучше модели ARMA

Сравним нашу модель с шестью переменными с моделью с трёхпеременной моделью (на данный момент лучшей):

```
[1] "Hosking, LiMcLeod: модель с 3 переменными"
```

```
lags statistic df p-value
54 296.418 243 0.01086519
```

```
lags statistic df p-value
54 300.0004 243 0.007405917
```

```
[1] "Hosking, LiMcLeod: модель с 5 переменными"
```

```
lags statistic df p-value
54 1404.099 972 0
```

```
lags statistic df p-value
54 1412.323 972 0
```

```
[1] "F-statistics"
```

```
[1] 0.9233216
```

```
[1] "F крит 1%"
```

```
[1] 1.313426
```

```
[1] "p-value"
```

```
[1] 0.6744667
```

Наша модель с шестью переменными хуже модели с тремя переменными.

По итогу, можно сказать, что только два выбранных фактора `def_aus`, `def_usa` улучшают прогноз валютного курса в сравнении с одномерной моделью временного ряда.

Прогноз на 5 лет:

